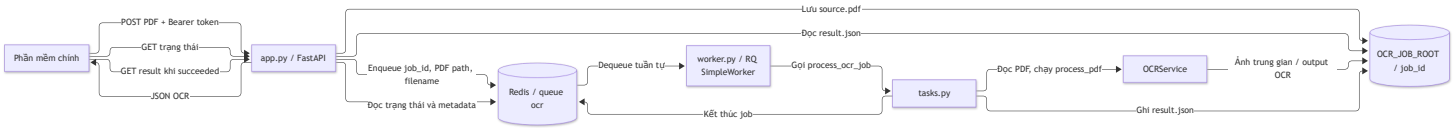
Data flow của API OCR

Thư mục này chứa lớp HTTP, cấu hình, worker RQ và tác vụ nối với pipeline OCR. Luồng chính là: phần mềm gọi API gửi PDF; API lưu PDF trên đĩa và đưa thông tin job vào Redis; worker lấy job, chạy OCR, rồi ghi JSON vào thư mục riêng của job.

Sơ đồ tổng quan



Redis chỉ giữ job, trạng thái, metadata và tham chiếu cần thiết. PDF nguồn, output trung gian và JSON kết quả nằm trên filesystem trong thư mục job; API và worker phải nhìn thấy cùng `OCR_JOB_ROOT`.

Luồng upload và enqueue

1. `app.py` nhận `POST /api/v1/jobs` và kiểm tra Bearer token.
2. API tạo `job_id` dạng UUID hex, tạo thư mục `OCR_JOB_ROOT/<job_id>/`, rồi ghi PDF thành `source.pdf`.
3. API kiểm tra giới hạn dung lượng, chữ ký `%PDF-`, khả năng đọc PDF và số trang.
4. API enqueue `process_ocr_job` vào queue tên `RQ_QUEUE_NAME` (mặc định `ocr`). Job truyền `job_id`, đường dẫn PDF và tên file; metadata gồm tên file, số trang và thời điểm tạo. PDF bytes không được đưa vào Redis.
5. API trả HTTP `202` cùng `job_id` và trạng thái ban đầu `queued`.

Nếu upload hoặc enqueue phát sinh lỗi, API xóa thư mục job vừa tạo rồi trả lỗi.

Luồng xử lý OCR

1. `worker.py` kết nối Redis, lắng nghe queue `ocr` bằng RQ `SimpleWorker`. Một worker xử lý từng job một.
2. Worker gọi `process_ocr_job` trong `tasks.py`.

3. Tác vụ kiểm tra lại đường dẫn và file nguồn, tạo thư mục `ocr_output/`, rồi khởi tạo `OCRService` khi cần và gọi `process_pdf`.
4. Tác vụ bỏ trường debug, chuẩn hóa metadata nguồn PDF, thêm `job_id` và ghi JSON vào `OCR_JOB_ROOT/<job_id>/result.json`.
5. Hàm tác vụ trả về một tham chiếu nhỏ tới file kết quả; payload OCR lớn không được trả về Redis.

Poll trạng thái và lấy kết quả

- `GET /api/v1/jobs/{job_id}`: `app.py` đọc job từ Redis và chuyển trạng thái RQ thành các giá trị API như `queued`, `running`, `succeeded` hoặc `failed`.
- `GET /api/v1/jobs/{job_id}/result`: API chỉ đọc và trả `result.json` khi job đã thành công; job chưa xong trả `409`, job hoặc file kết quả không tồn tại trả `404`.
- Job endpoints yêu cầu Bearer token. Health endpoint `/health` gọi `PING` Redis để xác nhận API kết nối được queue.

API không có endpoint liệt kê job hoặc callback. Phần mềm gọi API cần lưu `job_id` nhận được từ upload, poll endpoint trạng thái và gọi endpoint result khi job thành công.

Vai trò các file

File	Trách nhiệm
`settings.py`	Đọc cấu hình từ environment: Redis, token, đường dẫn job/config, giới hạn upload, retention và timeout.
`app.py`	Tạo FastAPI app, xác thực, nhận upload, enqueue job, trả trạng thái và JSON.
`worker.py`	Kết nối Redis và chạy một RQ worker tuần tự.
`tasks.py`	Kiểm tra input, gọi OCRService, làm sạch dữ liệu kết quả và ghi `result.json`.
`cleanup.py`	Preview hoặc xóa thủ công thư mục job quá hạn; mặc định chỉ liệt kê, `--apply` mới xóa.

Cấu hình liên quan

Các giá trị mặc định được đọc khi module được import:

Biến	Ý nghĩa
`REDIS_URL`	Redis URL, mặc định `redis://127.0.0.1:6379/0`.
`RQ_QUEUE_NAME`	Tên queue, mặc định `ocr`.
`OCR_API_TOKEN`	Bearer token bắt buộc cho job endpoints.
`OCR_JOB_ROOT`	Gốc lưu PDF, output và JSON; mặc định `output/ocr_api/jobs`.
`OCR_CONFIG_PATH`	Cấu hình OCR; mặc định `config/ocr.json`.
`MAX_UPLOAD_MB` / `MAX_PDF_PAGES`	Giới hạn upload và số trang.
`JOB_RETENTION_DAYS`	Thời gian giữ metadata/result/failure trong RQ và ngưỡng cleanup file.
`JOB_TIMEOUT_SECONDS`	Timeout của một job RQ.

API và worker phải dùng cùng `REDIS_URL`, `OCR_JOB_ROOT` và `OCR_CONFIG_PATH`.
Chỉ API cần `OCR_API_TOKEN` để xác thực request.

Cleanup

`cleanup.py` chỉ xét thư mục job có ID dạng 32 ký tự, đã quá retention và job đã kết thúc hoặc không còn trong Redis. Job queued/running được giữ lại. Chạy preview mặc định bằng:

```
.\.venv\Scripts\python.exe -m src.api.cleanup
```

Chỉ thêm `--apply` sau khi xem đúng danh sách cần xóa:

```
.\.venv\Scripts\python.exe -m src.api.cleanup --apply
```